

Desarrollo y validación de un modelo de visión artificial basado en YOLOv11n para la clasificación de hongos comestibles desecados según el CODEX STAN 39-1981 en la empresa SUMA YAPU, Cusco y Apurímac

Título del proyecto

Desarrollo y validación de un modelo de visión artificial basado en YOLOv11n para la clasificación de hongos comestibles desecados según el CODEX STAN 39-1981 en la empresa SUMA YAPU, Cusco y Apurímac. (Codex Alimentarius Commission, 1981a; Ultralytics, 2024)

Pregunta de la Investigación

¿En qué medida un modelo de visión artificial entrenado con YOLOv11n puede detectar y clasificar defectos visuales en hongos comestibles desecados conforme a las definiciones y tolerancias del CODEX STAN 39-1981, y cómo se compara su desempeño frente a la clasificación manual realizada por trabajadores entrenados de la empresa SUMA YAPU? (Codex Alimentarius Commission, 1981a; McNemar, 1947)

Subpreguntas: (a) ¿Qué protocolo de captura y qué guía de anotación aseguran consistencia del rotulado? (b) ¿Qué desempeño logra YOLOv11n por clase (precision, recall y mAP)? (c) ¿Qué diferencia existe entre humano y modelo y qué nivel de concordancia inter-evaluador presenta el método humano? (d) ¿Cuál es la diferencia en tiempo por inspección entre ambos métodos? (Lin et al., 2014; Fleiss, 1971)

Introducción

Descripción de la realidad problemática

La inspección de calidad en alimentos requiere procesos consistentes para cumplir estándares y reducir riesgos; sin embargo, la inspección visual manual puede ser lenta y variable entre evaluadores debido a fatiga y subjetividad, afectando la repetibilidad de las decisiones. (Meenu et al., 2021; Zhu et al., 2021)

En hongos comestibles desecados, el CODEX STAN 39-1981 define defectos e impurezas, y establece tolerancias cuantitativas para cada categoría; por ello, la clasificación operacional debe traducir dichas definiciones en criterios observables y medibles durante la inspección. (Codex Alimentarius Commission, 1981a)

En SUMA YAPU (Cusco y Apurímac), el proceso manual de clasificación depende del criterio del operario para identificar agujeros por larvas, vestigios de carbonización, piezas aplastadas o pies desprendidos, lo cual puede derivar en decisiones no uniformes y un mayor costo de inspección por lote. (Codex Alimentarius Commission, 1981a; Meenu et al., 2021)

La visión por computadora con aprendizaje profundo ofrece una alternativa no destructiva para automatizar la inspección visual mediante detección de objetos y clasificación, con modelos de una sola etapa (YOLO) capaces de operar en tiempo real. (Zhou et al., 2019; Redmon et al., 2016)

Este estudio delimita el alcance a defectos visibles e impurezas observables en imágenes, reconociendo que parámetros analíticos (p. ej., impurezas minerales como residuo insoluble en ácido) se definen por métodos de laboratorio y no se infieren directamente de RGB; por ello, se emplean proxies visuales y se declaran como limitación. (Codex Alimentarius Commission, 1981a; Meenu et al., 2021)

Antecedentes de la investigación

Revisiones recientes señalan el avance del aprendizaje profundo en evaluación de calidad de alimentos, con aplicaciones en detección de defectos y gradación, destacando como factores críticos la calidad del dataset, el control de iluminación y el balance de clases. (Zhu et al., 2021; Meenu et al., 2021)

En defectos agrícolas, se han reportado mejoras de YOLO para objetos pequeños y defectos sutiles; un ejemplo es la detección de defectos en kiwifruit con YOLOv5, mostrando viabilidad en tiempo real y métricas competitivas. (Yao et al., 2021; Lin et al., 2014)

En gradación por calidad, enfoques que combinan segmentación y detección con redes ligeras permiten operación en línea; por ejemplo, una propuesta para manzanas defectuosas integra segmentación semántica con un YOLOv4 podado para acelerar inferencia sin perder desempeño. (Liang et al., 2022; Bochkovskiy et al., 2020)

La literatura aplicada también reporta uso de YOLO en control de calidad de alimentos procesados; por ejemplo, un estudio de inspección en galletas con YOLOv5 respalda la factibilidad de automatizar inspecciones visuales en entornos productivos. (Li et al., 2023; Zhu et al., 2021)

Fundamento teórico

Las CNN son arquitecturas clave para tareas de visión, al aprender representaciones jerárquicas para clasificación y detección; su consolidación en aprendizaje profundo ha sido ampliamente descrita, incluyendo su eficacia en visión a gran escala y en tareas industriales. (Krizhevsky et al., 2012; LeCun et al., 2015)

La detección de objetos se evalúa con métricas como precision, recall y mAP basadas en IoU, ampliamente usadas en benchmarks (p. ej., COCO) para comparar modelos de forma estandarizada. (Lin et al., 2014; Powers, 2011)

YOLO plantea un detector de una sola etapa que realiza localización y clasificación en un único paso, habilitando inferencia rápida; sus variantes modernas optimizan el balance velocidad-precisión para despliegue. (Redmon et al., 2016; Bochkovskiy et al., 2020)

YOLOv11n (variante ‘nano’) prioriza eficiencia computacional, lo cual es pertinente para escenarios de despliegue con recursos limitados; por ello, se adopta como arquitectura base del presente estudio. (Ultralytics, 2024; Song et al., 2025)

En el marco normativo, el CODEX STAN 39-1981 establece el ámbito de aplicación, definiciones de productos, defectos e impurezas, y tolerancias; además, remite a la norma general para hongos comestibles y sus productos (CODEX STAN 38-1981) como requisito para materia prima, y a la norma general de etiquetado de alimentos preenvasados (CODEX STAN 1-1985) para disposiciones de etiquetado. (Codex Alimentarius Commission, 1981a, 1981b, 1985)

Tabla 1. Defectos e impurezas del CODEX STAN 39-1981 y su operacionalización para anotación

Categoría (CODEX)	Definición (resumen del estándar)	Unidad de anotación (YOLO)	Observación de operacionalización
Hongos dañados por larvas	Piezas con agujeros producidos por larvas.	Caja por pieza o por zona con agujeros.	Detección por textura/orificios; requiere buena iluminación.
Hongos gravemente	Piezas con cuatro o	Caja por pieza severa.	Definición basada en

dañados por larvas	más agujeros producidos por larvas.		conteo de agujeros; validar con expertos.
Hongos carbonizados	Piezas con vestigios de carbonización en su superficie.	Caja por zona o por pieza.	Riesgo de confusión con sombras; controlar iluminación.
Hongos dañados	Falta de > 1/4 del sombbrero (enteros) o > 1/3 de superficie (lonjas).	Caja por pieza dañada.	Requiere guía visual (ejemplos) para casos frontera.
Hongos aplastados	Partes que pasan por un tamiz de malla 5×5 mm.	Caja por fragmento (proxy visual).	El estándar es por tamiz; se propone proxy por tamaño relativo y escala.
Pies desprendidos	Pies separados de los sombbreretes.	Caja por pie desprendido o por pieza.	Regla de conformidad es relación 1:1; se operacionaliza por conteo.
Impurezas orgánicas	Otros hongos comestibles o partes vegetales (hojas,	Caja por impureza.	Visible; se registra y cuantifica como proxy por

	agujas de pino, etc.).		área/conteo.
Impurezas minerales	Residuo insoluble en ácido tras extracción de cenizas.	No se infiere plenamente en RGB.	Se registra solo si es visible; se declara limitación analítica.

Nota. Las definiciones se resumen del estándar; cuando el estándar usa medición física o analítica (tamiz, residuo insoluble), se propone proxy visual y se declara limitación. (Codex Alimentarius Commission, 1981a)

Tabla 2. Contenido máximo de agua según CODEX STAN 39-1981

Producto	Contenido máximo de agua (m/m)	Implicancia para control de calidad
Hongos liofilizados	$\leq 6\%$	Control de secado y almacenamiento para evitar rehidratación.
Hongos desecados (no liofilizados)	$\leq 12\%$	Condición general para otros hongos desecados.
Hongos desecados Shii-ta-ke	$\leq 13\%$	Umbral específico indicado por el estándar.

Nota. El contenido de agua se verifica por métodos de análisis; no se estima por imágenes.

(Codex Alimentarius Commission, 1981a)

Tabla 3. Tolerancias de defectos según CODEX STAN 39-1981 (resumen operativo)

Defecto/impureza	Tolerancia (m/m) según CODEX STAN 39-1981	Detalle/condición	Cómo se usa en la tesis

Impurezas minerales	$\leq 2\%$	Definidas por residuo insoluble en ácido.	Se reporta como fuera de alcance salvo evidencia visual; se limita a impurezas visibles.
Impurezas orgánicas	$\leq 0.02\%$ (excepto shiitake: $\leq 1\%$)	Excepción explícita para Shii-ta-ke.	Se cuantifica como proxy visual por área/conteo y se discute la diferencia con % m/m.
Hongos dañados por larvas	Silvestres: $\leq 20\%$ (total, incluyendo daño serio); cultivados: $\leq 1\%$ (total), incluyendo $\leq 0.5\%$ de daño serio	Tolerancia depende de origen (silvestre/cultivado).	Se estima por conteo de piezas o proxy por área; se alinea con ‘daño serio’ mediante clase ‘gravemente dañados’.
Hongos aplastados	$\leq 6\%$	Definición por tamiz 5×5 mm.	Se usa proxy visual con escala o regla por tamaño para aproximar el tamiz.
Hongos carbonizados	$\leq 2\%$	Vestigios de carbonización en superficie.	Se mide como proporción de piezas/área con

			carbonización.
Hongos dañados	$\leq 20\%$	Pérdida de superficie/parte del hongo.	Se operacionaliza por criterios visuales del estándar ($\geq 1/4$ o $\geq 1/3$).
Pies desprendidos	Relación pies:sombreretes = 1:1	Regla por conteo, no porcentaje.	Se aplica conteo de pies y sombreretes detectados.

Nota. El estándar también permite un máximo de 25% m/m de hongos que no satisfagan requisitos del producto final (Sección 3.3.1). (Codex Alimentarius Commission, 1981a)

Justificación

Justificación práctica, teórica y metodológica

Práctica: automatizar la inspección visual puede reducir tiempo por muestra y mejorar consistencia en la detección de defectos visibles, contribuyendo a decisiones más uniformes en la segregación de producto. (Meenu et al., 2021; Zhu et al., 2021)

Teórica: el estudio integra un estándar internacional de calidad (CODEX) con un detector moderno (YOLOv11n), aportando evidencia de desempeño en un dominio con variabilidad morfológica y defectos heterogéneos. (Codex Alimentarius Commission, 1981a; Zhou et al., 2019)

Metodológica: se formaliza un protocolo de captura, una guía de anotación validada por expertos y un esquema de evaluación comparativa (modelo vs humano) con métricas estandarizadas y pruebas pareadas. (Aiken, 1985; Lin et al., 2014)

Tabla 4. Comparación conceptual entre clasificación manual y clasificación con YOLOv11n

Criterio	Clasificación manual (humano)	Clasificación con YOLOv11n	Evidencia a recolectar
Consistencia	Varía por experiencia/fatiga y criterio.	Determinística para una misma imagen; depende del entrenamiento.	Kappa humano y exactitud vs verdad de referencia.
Tiempo por inspección	Mayor cuando el volumen es alto.	Inferencia rápida; requiere fase de entrenamiento.	Tiempo (s) por imagen/muestra en evaluación pareada.
Trazabilidad	Registro puede ser manual y no uniforme.	Salida digital reproducible (detecciones, clases).	Logs, matrices de confusión y reportes de métricas.
Cobertura CODEX	Puede incluir otros criterios no visuales.	Se limita a defectos visibles; % m/m es proxy si se usa área/conteo.	Declaración de alcance y limitaciones.

Nota. La comparación se fundamenta en literatura de inspección visual y en la naturaleza replicable del software. (Meenu et al., 2021; Ultralytics, 2024)

Objetivos de la investigación

Objetivo general

Desarrollar y validar un modelo de visión artificial basado en YOLOv11n para detectar y clasificar defectos visibles en hongos comestibles desecados según el CODEX STAN 39-1981, comparando su desempeño con la clasificación manual en SUMA YAPU. (Ultralytics, 2024; Codex Alimentarius Commission, 1981a)

Objetivos específicos

- Definir clases y criterios operativos de defectos/impurezas visibles a partir del CODEX STAN 39-1981. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)
- Diseñar y aplicar un protocolo de captura de imágenes que controle iluminación, fondo, distancia y escala. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)
- Construir un dataset etiquetado en formato YOLO con auditoría de etiquetas y partición train/val/test por lote o sesión. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)
- Entrenar YOLOv11n y documentar hiperparámetros y configuración final del modelo. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)
- Evaluar desempeño con métricas de detección (precision, recall, mAP) y matrices de confusión por clase.
- Comparar el desempeño y tiempo de inspección del modelo frente a evaluadores humanos mediante pruebas pareadas. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)

Formulación de hipótesis

Hipótesis general

El modelo YOLOv11n entrenado con una guía de anotación validada alcanzará un desempeño de clasificación comparable o superior al método humano en el conjunto de prueba y reducirá el tiempo promedio de inspección por unidad evaluada. (McNemar, 1947; Ultralytics, 2024)

Hipótesis específicas

- H1: El modelo alcanzará valores altos de precision, recall y mAP en las clases de defectos/impurezas visibles definidas. (Fleiss, 1971; McNemar, 1947)
- H2: La concordancia inter-evaluador en el método humano presentará variabilidad medible (κ) debido a ambigüedad de casos frontera.
- H3: Existirá diferencia estadísticamente significativa en la proporción de aciertos entre humano y modelo (McNemar) en decisiones pareadas.

Materiales y Métodos

Diseño de la investigación

Tipo

Investigación aplicada y de desarrollo tecnológico, orientada a implementar un modelo de detección y validar su uso en un proceso de inspección visual de calidad basado en estándares. (Zhu et al., 2021; Zhou et al., 2019)

Enfoque

Enfoque cuantitativo, con evaluación del desempeño mediante métricas de detección y contraste estadístico pareado (humano vs modelo), y evaluación de acuerdo entre evaluadores para estimar confiabilidad de la clasificación manual. (Powers, 2011; Fleiss, 1971)

Población

Imágenes de muestras de hongos comestibles desecados (enteros o en lonjas) y posibles impurezas visibles, procedentes de lotes gestionados por SUMA YAPU en Cusco y Apurímac durante el periodo de investigación. (Codex Alimentarius Commission, 1981a; Zhu et al., 2021)

Muestra

Muestreo no probabilístico por conveniencia, buscando cubrir todas las clases de defectos visibles (larvas, carbonización, daño, aplastado, pies desprendidos) y escenarios de variación (iluminación, tamaño, fondo). Se recomienda asegurar suficientes instancias por clase y separar el conjunto de prueba para evaluación final. (Song et al., 2025; Zhu et al., 2021)

Tabla 5. Plan sugerido de partición del dataset

Conjunto	Propósito	Proporción sugerida	Recomendación de control
Entrenamiento	Aprender parámetros del modelo	70%	Balancear clases; augmentations controladas.

Validación	Ajuste de hiperparámetros y early stopping	20%	No mezclar con prueba; monitorear sobreajuste.
Prueba	Evaluación final y comparación con humanos	10%	Etiquetas auditadas; sin leakage de lotes similares.

Nota. Particionar por lote o sesión de captura reduce fuga de información y sobreestimación del desempeño. (Zhu et al., 2021; Song et al., 2025)

Técnicas para la recolección de datos

Descripción de los instrumentos

Instrumento 1 (Protocolo de captura): establece iluminación difusa, fondo uniforme, distancia fija y control de sombras; cuando se requiera aproximar el criterio de ‘aplastado’ por tamiz, se incorpora una escala visual para convertir tamaño relativo en regla proxy. (Meenu et al., 2021; Codex Alimentarius Commission, 1981a)

Instrumento 2 (Guía de anotación): traduce definiciones del CODEX STAN 39-1981 en reglas de etiquetado, incluyendo ejemplos y criterios de casos frontera, especialmente para ‘hongos dañados’ y ‘gravemente dañados por larvas’ basados en conteo de agujeros. (Codex Alimentarius Commission, 1981a; Aiken, 1985)

Instrumento 3 (Ficha de evaluación humana): lista de cotejo por imagen con presencia/ausencia de clases y decisión final (apto/no apto) según reglas operativas; incluye registro de tiempo por imagen. (McNemar, 1947; Fleiss, 1971)

Instrumento 4 (Bitácora de entrenamiento): registra hiperparámetros, versión de software, particiones y métricas por época, asegurando trazabilidad del proceso de entrenamiento y evaluación. (Ultralytics, 2024; Zhu et al., 2021)

Tabla 6. Cuadro de instrumentos (operacionalización resumida)

Variable	Dimensión	Indicadores	Técnica	Instrumento	Escala
Método de clasificación	Tipo de evaluador	Humano / YOLOv11n	Observación comparativa	Ficha de evaluación por imagen	Nominal
Desempeño de clasificación	Exactitud	Accuracy, precision, recall, F1, mAP	Análisis computacion al	Reporte de métricas / matriz de confusión	Razón
Desempeño de clasificación	Sensibilidad/ Especificidad	TPR, TNR (por clase o binario)	Análisis computacion al	Matriz de confusión	Razón
Eficiencia del proceso	Tiempo de inspección	Segundos por imagen/muestra	Cronometría	Registro de tiempos	Razón
Consistencia del rotulado	Concordancia inter-evaluador	Kappa / acuerdo %	Juicio de expertos	Planilla de concordancia	Razón

Nota. Las métricas de desempeño y acuerdo se reportan según práctica estándar en evaluación de clasificadores. (Powers, 2011; Fleiss, 1971)

Validez y confiabilidad de los instrumentos

Validez de contenido: expertos evaluarán la pertinencia y claridad de la guía de anotación y la ficha de evaluación; se calculará V de Aiken por ítem para cuantificar el consenso y refinar definiciones operativas. (Aiken, 1985; Codex Alimentarius Commission, 1981a)

Confiabilidad de clasificación manual: se estimará kappa (Cohen o Fleiss) para medir acuerdo más allá del azar entre evaluadores humanos; adicionalmente, se realizará capacitación breve con ejemplos para reducir ambigüedad antes de la evaluación formal. (Cohen, 1960; Fleiss, 1971)

Confiabilidad del rotulado/dataset: se auditará una fracción del dataset con revisión experta y corrección de etiquetas; se documentarán criterios de inclusión de instancias y resolución de discrepancias. (Zhu et al., 2021; Lin et al., 2014)

Técnica para el procesamiento y análisis de datos

Entrenamiento: se usará la implementación de Ultralytics para YOLOv11n; se entrenará con partición train/val, ajustes básicos de augmentations y early stopping, y se seleccionará el mejor modelo por desempeño en validación. (Ultralytics, 2024; Lin et al., 2014)

Operacionalización cuantitativa (proxy): para aproximar tolerancias % m/m desde imágenes, se registrará la proporción por defecto usando conteo de piezas o área relativa (p. ej., $\text{Área defectuosa} / \text{Área total} \times 100\%$), reconociendo que se trata de un proxy respecto a la medida por masa del estándar. (Codex Alimentarius Commission, 1981a; Meenu et al., 2021)

Evaluación técnica: se calcularán precision, recall y mAP por clase, junto con matrices de confusión y análisis de errores (falsos positivos/negativos) en el conjunto de prueba. (Lin et al., 2014; Powers, 2011)

Comparación humano vs modelo: ambos métodos se evaluarán sobre las mismas imágenes, contrastando contra una verdad de referencia definida por consenso experto o auditoría; se aplicará McNemar para diferencia de proporciones pareadas y kappa para acuerdo humano. (McNemar, 1947; Fleiss, 1971)

Análisis de eficiencia: el tiempo por imagen/muestra se analizará con estadísticos descriptivos y contraste pareado (t pareada o Wilcoxon según supuestos). (Powers, 2011; Zhu et al., 2021)

Aspectos Éticos

La participación de evaluadores humanos será voluntaria y con consentimiento informado; los resultados se reportarán de manera agregada para no afectar evaluaciones laborales individuales, y se protegerá la confidencialidad de datos internos. (Fleiss, 1971; Zhu et al., 2021)

El estudio no interviene el producto más allá de captura fotográfica y se alinea a buenas prácticas de higiene y manipulación recomendadas por el Codex para productos alimenticios. (Codex Alimentarius Commission, 1969; Codex Alimentarius Commission, 1981a)

Limitaciones de la investigación

El modelo se limita a defectos e impurezas visibles; no reemplaza ensayos fisicoquímicos o microbiológicos, ni la determinación analítica de impurezas minerales como residuo insoluble en ácido, por lo que su uso se restringe a soporte de inspección visual. (Codex Alimentarius Commission, 1981a; Meenu et al., 2021)

La traducción de tolerancias % m/m a medidas basadas en imágenes requiere proxies (área/conteo), lo cual puede introducir sesgo; esta limitación debe discutirse y, cuando sea posible, validarse correlacionando proxy visual con medición por masa en submuestras. (Codex Alimentarius Commission, 1981a; Zhu et al., 2021)

La generalización del modelo depende del rango de condiciones capturadas (iluminación, fondo, especies/presentaciones y distribución de defectos); por ello, se recomienda capturar datos representativos y auditar sesgos del dataset. (Song et al., 2025; Zhu et al., 2021)

Cronograma

Cronograma tentativo por fases para captura, rotulado, entrenamiento, evaluación y redacción; ajustable al calendario académico y a disponibilidad de lotes. (Ultralytics, 2024; Zhu et al., 2021)

Tabla 7. Cronograma tentativo (editable)

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Definición de esquema de clases y protocolos	X	X				
Captura de imágenes y control de calidad		X	X			
Etiquetado/ anotación y auditoría		X	X	X		
Entrenamiento y ajuste de			X	X		

YOLOv11 n						
Evaluación técnica (métricas)			X	X	X	
Comparación con evaluadores humanos				X	X	
Análisis estadístico y discusión					X	X
Redacción final y sustentación						X

Nota. Se sugiere incluir una fase explícita de auditoría de etiquetas y una fase de comparación humano vs modelo. (Zhu et al., 2021)

Presupuesto

Plantilla de presupuesto por rubros; completar con costos reales y cotizaciones, considerando que herramientas open-source pueden reducir el costo total. (Ultralytics, 2024; Meenu et al., 2021)

Tabla 8. Presupuesto (plantilla editable)

Rubro	Descripción	Unidad	Cantidad	Costo	Costo total
-------	-------------	--------	----------	-------	-------------

				unitario (S/)	(S/)
Captura de datos	Iluminación / fondo / soporte cámara	set			
Etiquetado	Horas de anotación (personal o tesista)	hora			
Computación	GPU/servicio de cómputo (si aplica)	mes			
Software	Herramientas (principalme nte open- source)	-		0	0
Movilidad	Traslados para captura (si aplica)	viaje			
Impresión/ encuadernado	Versión final	unidad			
Contingencia	10% del total	-			

Nota. Completar con cotizaciones; describir licencias y recursos institucionales utilizados. (Zhu et al., 2021)

Referencias bibliográficas

- Aiken, L. R. (1985). Three coefficients for analyzing the reliability and validity of ratings. *Educational and Psychological Measurement*, 45(1), 131–142.
- Bochkovski, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). YOLOv4: Optimal speed and accuracy of object detection. arXiv. <https://arxiv.org/abs/2004.10934>
- Codex Alimentarius Commission. (1969). General principles of food hygiene (CAC/RCP 1-1969). FAO/WHO.
- Codex Alimentarius Commission. (1981a). Standard for dried edible fungi (CODEX STAN 39-1981). FAO/WHO.
- Codex Alimentarius Commission. (1985). General standard for the labelling of prepackaged foods (CODEX STAN 1-1985). FAO/WHO.
- Codex Alimentarius Commission. (1981b). Standard for edible fungi and fungus products (CODEX STAN 38-1981). FAO/WHO.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5), 378–382.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.

- Li, T., Zhao, Y., & Huang, X. (2023). Biscuit quality detection based on YOLOv5. *Applied Sciences*, 13(21), 11671. <https://doi.org/10.3390/app132111671>
- Liang, X., Jia, X., Huang, W., He, X., Li, L., Fan, S., Li, J., Zhao, C., & Zhang, C. (2022). Real-time grading of defect apples using semantic segmentation combination with a pruned YOLO V4 network. *Foods*, 11(19), 3150. <https://doi.org/10.3390/foods11193150>
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *Proceedings of the European Conference on Computer Vision (ECCV) Workshops*.
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12, 153–157.
- Meenu, M., Kurade, C., Neelapu, B. C., Kalra, S., Ramaswamy, H. S., & Yu, Y. (2021). A concise review on food quality assessment using digital image processing. *Trends in Food Science & Technology*, 118(Part A), 106–124. <https://doi.org/10.1016/j.tifs.2021.09.014>
- Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 779–788).
- Song, J., Kim, D., Jeong, E., & Park, J. (2025). Determination of optimal dataset characteristics for improving YOLO performance in agricultural object detection. *Agriculture*, 15(7), 731. <https://doi.org/10.3390/agriculture15070731>

Ultralytics. (2024). Ultralytics YOLO11 documentation. <https://docs.ultralytics.com>

Yao, J., Qi, J., Zhang, J., Shao, H., Yang, J., & Li, X. (2021). A real-time detection algorithm for kiwifruit defects based on YOLOv5. *Electronics*, 10(14), 1711.

<https://doi.org/10.3390/electronics10141711>

Zhou, L., Zhang, C., Liu, F., Qiu, Z., & He, Y. (2019). Application of deep learning in food: A review. *Comprehensive Reviews in Food Science and Food Safety*, 18(6), 1793–1811.

<https://doi.org/10.1111/1541-4337.12492>

Zhu, L., Spachos, P., Pensini, E., & Plataniotis, K. N. (2021). Deep learning and machine vision for food processing: A survey. *Current Research in Food Science*, 4, 233–249.

<https://doi.org/10.1016/j.crfs.2021.03.009>

Anexos

Anexo 2. Matriz de consistencia

La matriz de consistencia articula la pregunta, objetivos, hipótesis, variables e indicadores, y define la estrategia de contraste pareado humano vs modelo mediante pruebas de concordancia y diferencia de proporciones. (Fleiss, 1971; McNemar, 1947)

Nivel	Problema / Pregunta	Objetivo	Hipótesis	Variables	Indicador es / Métricas	Técnica e instrume nto	Análisis
General	¿En qué medida un modelo de visión artificial entrenado con YOLOv1 1n puede detectar y clasificar defectos visuales en	Desarrollar y validar un modelo de visión artificial basado en YOLOv1 1n para detectar y clasificar defectos visibles en	El modelo YOLOv1 1n entrenado con una guía de anotación validada alcanzará un desempeño ño de clasificac ión	VI: Método de clasificac ión (humano vs YOLOv1 1n) VD: Desempe ño de clasificac ión y	mAP@0.5, mAP@0.5:0.95, precision, recall, F1; kappa; tiempo por imagen	Ficha de evaluación humana; inferencia YOLOv1 1n; registro de tiempos	Métricas de detección; kappa; prueba de McNemar; comparac ión de tiempos

	hongos comestibles desecados según el conforme a las definiciones y tolerancias del CODEX STAN 39-1981, y cómo se compara su desempeño frente a la clasificación	hongos comestibles desecados según el CODEX STAN 39-1981, comparando su desempeño con la clasificación manual en SUMA YAPU. (Ultralytics, 2024; Codex Alimentarius	comparables o superior al método humano en el conjunto de prueba y reducirá el tiempo promedio de inspección por unidad evaluada. (McNemar, 1947; Ultralytics, 2024)	tiempo			
--	---	--	---	--------	--	--	--

	manual realizada por trabajadores entrenados de la empresa SUMA YAPU? (Codex Alimentarius Commission, 1981a; McNemar, 1947)	Commission, 1981a)					
Específico 1	Definición operativa de clases CODEX	Definir clases y criterios operativo s de	—	Variable de control: operacion alización	Lista de clases; criterios de inclusión/	Guía de anotación ; revisión experta	Validación de contenido (V de Aiken) y

		defectos/impurezas visibles a partir del CODEX STAN 39-1981. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)		de defectos	exclusión ; tolerancias CODEX		ajustes del codebook
Específico 2	Captura estandarizada de imágenes	Diseñar y aplicar un protocolo de captura de imágenes que	—	Variable de control: calidad de imagen	Iluminación, fondo, distancia; tasa de imágenes válidas	Protocolo de captura; checklist de captura	Control de calidad y exclusión de imágenes no válidas

		controle iluminaci ón, fondo, distancia y escala. (Codex Alimenta rius Commiss ion, 1981a; Lin et al., 2014)					
Específic o 3	Dataset y rotulado consisten te	Construir un dataset etiquetad o en formato YOLO con auditoría	—	Variable de control: consisten cia de etiquetas	Kappa/ Cohen- Fleiss entre anotadore s; tasa de correcció n en auditoría	Guía de anotación ; auditoría de etiquetas	Estimaci ón de confiabili dad y depuració n del dataset

		de etiquetas y partición train/val/test por lote o sesión. (Codex Alimenta rius Commiss ion, 1981a; Lin et al., 2014)					
Específico o 4	Entrenamiento documentado del modelo	Entrenar YOLOv1 en y documentar hiperparámetros y	H1: desempeño alto por clase	VI (operacional): modelo YOLOv1 en entrenado	Curvas de entrenamiento; métricas por época	Código de entrenamiento; bitácora de experimente	Comparación de configuraciones y selección de mejor checkpoi

		configuración final del modelo. (Codex Alimentarius Commission, 1981a; Lin et al., 2014)		(pesos, hiperparámetros)		ntos	nt
o 5	Evaluación comparativa humano vs modelo	Evaluar desempeño con métricas y comparar contra humanos.	H2-H3: variabilidad humana (kappa) y diferencia de aciertos (McNemar)	VD: desempeño y eficiencia	Matriz de confusión; kappa; McNemar; tiempo	Ficha humana; inferencia; registro de tiempo	Análisis estadístico y reporte de resultados

Anexo 3. Matriz de operacionalización

La operacionalización traduce los conceptos de calidad según la norma y el desempeño del modelo en variables medibles, alineando indicadores y métricas de evaluación. (Codex Alimentarius Commission, 1981a; Powers, 2011)

Variable	Definición conceptual	Definición operacional	Dimensión	Indicador	Escala / unidad	Técnica	Instrumento / fuente
VI: Método de clasificación	Procedimiento usado para identificar defectos e impurezas y decidir conformidad del producto.	Dos niveles: (a) inspección manual realizada por trabajadores entrenados; (b) inferencia automática con	Tipo de método	Manual / Automático	Nominal (2 categorías)	Observación estructurada	Ficha de evaluación humana; registro de inferencias

		YOLOv1 1n sobre imágenes estandari zadas.					
VD: Desempe ño de clasificac ión	Capacida d de identifica r correcta mente defectos/i mpurezas conforme a definicio nes del CODEX STAN 39-1981.	Compara ción contra verdad de referenci a (ground truth) en test; evaluació n por clase y global.	Exactitud por clase	Precision, recall, F1 por clase	0–1 (proporci ón)	Evaluaci ón de modelos	Reporte de métricas YOLO (Ultralyti cs)
VD: Desempe ño de	Capacida d de identifica	Cálculo de promedio	Rendimie nto global	mAP@0. 5 y mAP@0.	0–1 (proporci ón)	Evaluaci ón de modelos	Reporte de métricas

clasificación	r correcta mente defectos/i mpurezas conforme a definicio nes del CODEX STAN 39-1981.	de precisión por umbrales IoU, según práctica estándar en detección .		5:0.95			YOLO (Ultralytics)
VD: Concordancia humano– modelo	Grado de acuerdo entre decisione s del humano y del sistema, más allá del azar.	Cálculo de kappa (Cohen) para dos evaluador es o Fleiss para múltiples, sobre etiquetas	Concordancia	Kappa	–1 a 1	Estadística de confiabilidad	Matriz de decisiones; cálculo kappa

		pareadas.					
VD: Diferencia de proporciones de acierto	Diferencia entre dos métodos en decisiones pareadas sobre los mismos casos.	Prueba de McNemar sobre tabla 2×2 (humano vs modelo) usando decisiones correctas/incorrectas pareadas.	Contraste pareado	χ^2 de McNemar, p-valor	p-valor (<0.05)	Prueba de hipótesis	Tabla pareada; McNemar
VD: Eficiencia temporal	Tiempo requerido por método para emitir una decisión	Medición cronometrada del tiempo por imagen/lote en humano y	Tiempo	Segundos por unidad	s	Medición de tiempos	Registro de tiempos (cronómetro/log)

	por unidad evaluada.	tiempo de inferenci a del modelo.					
Variable de control: Calidad del rotulado	Grado en que las etiquetas represent an correcta mente los defectos definidos por la norma.	Validació n por expertos de la guía de anotación y auditoría de una muestra del dataset.	Validez de contenido	V de Aiken	0–1	Juicio de expertos	Formato de valoració n de ítems
Variable de control: Calidad del rotulado	Grado en que las etiquetas represent an correcta mente los	Estimaci ón de acuerdo entre anotadore s (Cohen/F	Confiabil idad interanot ador	Kappa (Cohen/F leiss)	–1 a 1	Estadístic a de confiabili dad	Subconju nto rotulado por 2+ anotadore s

	defectos definidos por la norma.	leiss) sobre un subconju nto doblemen te rotulado.					
--	---	--	--	--	--	--	--

Anexo 4. Encuesta / instrumento de evaluación

El instrumento integra (i) ficha de evaluación manual para generar etiquetas humanas comparables y (ii) guía de anotación para rotulado en formato YOLO, en concordancia con definiciones y tolerancias del CODEX STAN 39-1981. (Codex Alimentarius Commission, 1981a; Aiken, 1985)

Anexo 4A. Ficha de evaluación manual (por imagen / unidad)

Instrucciones: Para cada imagen, registre el tipo de presentación del hongo y marque los defectos visibles. Si existen varios defectos, marque todos los aplicables. (Codex Alimentarius Commission, 1981a)

Campo	Descripción / opciones	Registro
Código de imagen	Identificador único (p. ej., Lote_001_IMG_0001).	
Fecha y hora	Momento de evaluación.	

Evaluador	Iniciales o código del trabajador.	
Tipo de presentación	Entero / Sombrero sin pie / Lonjas / Otro.	
Defecto: dañado	Cap con >1/4 faltante o lonja con >1/3 faltante.	Sí / No
Defecto: carbonizado	Trazas de carbonización en la superficie.	Sí / No
Defecto: aplastado	Deformación evidente por presión/compactación.	Sí / No
Defecto: daño por larvas	Agujeros compatibles con larvas; indicar severidad si aplica.	No / Leve / Severo
Impureza vegetal	Presencia de hojas, agujas de pino u otras partes vegetales.	Sí / No
Impureza mineral	Presencia de tierra/piedras/arena visibles.	Sí / No
Pie desprendido	Pie separado del sombrero visible (conteo si aplica).	Nº
Etiqueta final (clase)	Clase principal para análisis (Normal / Dañado / Carbonizado / Aplastado / Larvas / Impureza vegetal /	

	Impureza mineral / Pie desprendido).	
Observaciones	Casos frontera, dudas o condiciones anómalas.	

Anexo 4B. Guía de anotación para YOLO (codebook)

Regla general: etiquetar el objeto visible (hongo o impureza) con una caja delimitadora mínima que lo contenga sin incluir fondo innecesario; usar la clase según definición operacional y priorizar coherencia entre anotadores. (Lin et al., 2014; Ultralytics, 2024)

ID clase	Nombre de clase	Definición operacional (resumen)	Criterios de inclusión / exclusión	Notas de rotulado
0	normal	Hongo sin defectos visibles relevantes según CODEX STAN 39-1981.	Excluir si presenta cualquier defecto/impureza visible.	Caja sobre el hongo completo.
1	danado	Pérdida de material: >1/4 del sombrerete faltante (enteros) o >1/3 de superficie	Incluir aunque tenga otros defectos; si coexisten, registrar multi-etiqueta en ficha	Caja sobre el hongo completo; si se etiqueta multi-clase, mantener

		faltante (lonjas).	manual y priorizar clase principal definida en el protocolo.	consistencia.
2	carbonizado	Trazas oscuras compatibles con carbonización.	Excluir manchas por sombra; incluir si la zona oscura es propia del tejido.	Caja sobre el hongo completo o sobre el área si se modela defecto localizado (definir estrategia).
3	aplastado	Deformación visible por compresión/rotur a.	Excluir si es solo variación natural de forma sin señales de presión.	Caja sobre el hongo completo.
4	larvas	Holes visibles atribuibles a larvas/maggots.	Excluir perforaciones mecánicas claras; incluir si hay patrón de	Caja sobre el hongo completo; opcional: caja sobre zona con orificios si se

			orificios.	quiere localizar.
5	impureza_vegetal	Hojas, agujas, tallos u otras partes vegetales no pertenecientes al hongo.	Excluir parte del propio hongo; incluir solo cuerpos extraños vegetales.	Caja solo sobre la impureza.
6	impureza_mineral	Tierra, arena o piedras visibles.	Excluir sombras o fondo; incluir únicamente partículas minerales.	Caja solo sobre la impureza.
7	pie_desprendido	Pie separado del sombrerete visible como unidad.	Excluir pies aún unidos; incluir pies sueltos.	Caja sobre el pie suelto.

Anexo 4C. Registro de tiempo (por sesión)

Registrar el tiempo por imagen/unidad permite comparar eficiencia entre el método humano y el modelo en condiciones equivalentes. (Powers, 2011)

Método	Inicio	Fin	Nº imágenes evaluadas	Tiempo total (s)	Tiempo promedio por

					imagen (s)
Humano / Modelo					